

多条记忆的整理：现有能力与改进方案

先钉住"记忆怎么被选出来"，再谈怎么改

项目	睿乐大脑·整理模块
版本	V1（基于代码核查）
核查范围	选记忆/装配/就绪/落库
结论	筛选能力已就绪、只差接线

3

真实可用路径

1

推荐先做的改动

5

已识别卡点

多条记忆的整理：现有能力与改进方案

前置：招生顾问Agent可行性核查.md（记忆模块真实边界）、整理能力与10个模板匹配度评估.md（模板能力匹配度）

结论先行

1. 能做，而且平台已经有一条零开发的可用路径（定时 / 立即整理，自动取最近一批记忆聚合）。但它的选材规则是写死的：「最近 50 条、按发生时间倒序」，不能按类型 / 关键词 / 客户选。
2. 真正卡住的不是「能不能合并」，而是三件事：范围不可指定、一条未就绪整批失败、超出预算静默截断。
3. 好消息：按类型 / 关键词筛选的底层能力已经就绪 —— `ListMemories` 支持 `Kind` 精确过滤 + `Keyword`（title/content/source）模糊匹配（`internal/application/repository/organize.go:160-163`），只是整理任务「选记忆」那一步没把参数传下去。最小接线的工作量集中在1个函数 + 1个配置字段。

一、现状：把多条记忆送进整理的四个部件

部件	代码位置	真实行为
选记忆	<code>organize_workbench.go:550-573</code>	有传入 ID 就用传入；否则取最近 50 条。构造查询时只传 <code>TenantID/UserID/Page/PageSize</code> , <code>Kind / Keyword</code> 都留空
装配提示词	<code>organize_workbench.go:904-952</code>	每条记忆标 <code>[M#]</code> 标题/类型/时间/来源/内容；单条截断 2200 字符；总量预算 18000；先写后判 + 整体尾部硬截断 → 超出部分静默丢弃，用户无感知
就绪校验	<code>organize.go:274-300</code>	选中集合里任何一条附件未就绪 / 转写未完成 → 整批抛 <code>ErrOrganizeMemoryNotReady</code> ；只有 <code>allow_partial=true</code> 才放行
输出落库	<code>organize_workbench.go:636-668</code>	正文为 Markdown（强制保留章节 + <code>{{citations}}</code> + <code>{{tags}}</code> ）； <code>fields</code> 只落 6 个系统级元数据（主题/模板/版本/时间范围/待办数/来源数），不是业务字段

关键常数（`organize_workbench.go:30-33`）：

常数	值	含义
<code>organizeJobMemoryLimit</code>	50	默认取数上限（仅在未指定 ID 时生效）
<code>organizeJobPromptBudget</code>	18000	提示词总预算（字符）
单条截断	2200	<code>sampleRunes(content, 2200, "...")</code>

容量参考：18000 ÷ 2200 ≈ 8 条最坏情况（每条都写满）；按一线常见的 AI 笔记长度（约 800—1200 字符）估，实际约 15—25 条。超过即被尾部截断。

二、三条真实可用的路径

路径	入口	能否指定记忆范围	触发方式	现状
A 定时配置	<code>POST /organize/configs</code> (含 <code>schedule</code>)	✗ 只能吃默认「最近 50 条」	<code>daily</code> 08:00 / <code>weekly</code> 周一 09:00 / <code>monthly</code> 1 日 09:00 (Asia/Shanghai)	✅ 已接线, 零开发
B 立即整理	<code>POST /organize/configs/:id/run</code>	✗ 同上	手动点「立即整理」	✅ 已接线
C 手动建任务	<code>POST /organize/jobs</code>	✅ API 支持 <code>memory_ids</code> 数组 + <code>allow_partial</code>	单次	💎 前端只传单条, 无多选 UI

说明: `OrganizeJobInput.memory_ids` (`frontend/src/api/organize/index.ts:375-381`) 是真实能力, 但前端两个发起点 (`OrganizeDocumentEditor.vue:1230-1231`、`OrganizeWorkspace.vue:1732-1733`) 都是 `memory_ids: [单条 ID]`。配置页「立即整理」也不传 (`OrganizeConfigDetail.vue:216-220`) , 等价于走路径 A 的默认取数。

三、五个卡点（其中三个是「有定义、零消费」）

- 范围不可指定 → `createScheduledOrganizeJob` 调 `selectOrganizeJobMemoryIDs(..., nil)` (`organize_workbench.go:801`) , 完全不读 `config`。这是"批量整理只能吃全量"的主因。
- 一条未就绪 → 整批失败 → `organize.go:290-297`。而 `allow_partial` 前端只声明、无调用点 (`api/organize/index.ts:248,380`) 。
- 预算静默截断 → `:945-952` 先写后判。且 `validateMemoryIDs` (`organize.go:954-967`) 不校验条数上限: 传 200 个合法 ID 不报错, 只是静默丢弃大部分。
- `config.Metadata` 零消费 → DB 是 jsonb、前后端类型都有这个字段 (`types/organize_workbench.go:154`、`api/organize/index.ts:84`) , 但调度时从没读过它。← 最

干净的扩展点

5. 无多选 UI → 记忆列表只有前端本地关键词过滤（`OrganizeWorkspace.vue:642, 851-857`），一次拉 100 条再本地筛，没有勾选 / 全选 / 批量。

四、方案：四层，按成本升序

L0 | 今天就能用（零开发，0 行代码）

用现成的定时配置（或配置页「立即整理」），接受「最近一批」的范围规则。

- 适合：每日线索跟进清单、每周渠道/复盘周报、每月成交与流失复盘。
- 不适合：按客户 / 按主题 / 只挑某几类记录的聚合。
- 必须告知用户：结果只覆盖最近的一批记忆，不是全部。否则会误判成「AI 漏了」。

L1 | 给「选记忆」接线筛选条件（推荐先做）

把筛选条件挂到已经存在但没人读的 `config.Metadata`，在 `selectOrganizeJobMemoryIDs` 里读出来，填进 `OrganizeListQuery`。

```
{
  "memory_filter": {
    "kinds": ["record", "audio_card"],
    "keyword": "试听",
    "limit": 30,
    "allow_partial": true
  }
}
```

项	内容
后端 改动	1 处: <code>organize_workbench.go:550-573</code> 增加「读 config.Metadata → 填 <code>Kind / Keyword / PageSize</code> 」; <code>:801</code> 把 config 传进去
仓储 改动	0 —— <code>ListMemories</code> 已支持 <code>Kind</code> 精确 + <code>Keyword</code> 模糊 (<code>repository/organize.go:160-163</code>), 排序 <code>occurred_at DESC</code> 现成
前端 改动	配置表单加 2 个控件 (记忆类型下拉、关键词输入)
能力 边界	✅ 按类型 / 关键词筛; ❌ 不支持时间范围 (<code>ListMemories</code> 没有 <code>occurred_at</code> 条件下推, 要新增属 L1.5)
收益	定时 / 立即整理从「只能吃全量」变成「只整理录音类」「只整理含'试听'的」

这是性价比最高的一步: 仓储能力已经躺在那儿, 接线成本远小于新建功能, 且不需要改数据模型。

L2 | 前端多选 + 批量发起

- 只改前端: 记忆列表加勾选 + 「批量整理」入口 → `POST /organize/jobs` 带 `memory_ids: [...]` (API 已就绪)。
- 必须同时做两件事, 否则会踩坑: 1. 显示覆盖提示: 「已选 N 条 / 上限 M 条 / 超出将被截断」; 2. 带 `allow_partial: true`, 否则选中的批量里只要有一条录音还在转写, 整批直接失败。
- 同时建议服务端在 `validateMemoryIDs` 加条数上限校验并明确报错 (现在是不报错、静默丢)。

L3 | 真正按主体聚合 (数据模型改动, 慎做)

要做到「按某个家长 / 某个主题聚合记忆», 必须补 `subject_id` (或引入「记忆集合」概念)。这属于数据模型演进, 不是提示词能解决的 —— 与 [招生顾问Agent可行性核查.md](#) 的结论一致。

横切 | 预算分段策略

当候选记忆超过预算承载量时, 二选一:

策略	做法	代价
切分	按时间窗口 / 类型拆成多个任务分别跑, 产出多份成果	需前端或调度侧支持分批
提示	成果上显示「本次覆盖 N / M 条记忆」	极小 (推荐先做这个)

五、推荐落地路线

批次	内容	成本
第一批	L1 接线筛选 + <code>allow_partial</code> 接线 + 成果页「覆盖 N/M 条」提示	后端 1 函数 + 前端 2 控件
第二批	L2 记忆列表多选 + 批量发起（含覆盖提示与 <code>allow_partial</code> ）	纯前端
第三批（按需）	L1.5 时间范围筛选 → L3 <code>subject_id</code> 主体聚合	中 → 大

六、一句话口径

现在就能做「按定时把最近一批记忆整理成清单」，也能做「按类型 / 关键词圈定一批来整理」（只差一次接线）；但还不能做「按某个客户或某个主题自动聚合」——那需要先补数据模型。