

整理准确性实测

10 个整理模板准确性实测报告

口语化录音导入记忆 · 逐模板跑整理 · 多条聚合验证拆批合并

项目 睿乐大脑 · 整理模块
环境 本地 8080/8081/8082
工作区 满乐乐 (tenant 10001)
日期 2026-10-07

12

实测整理任务

10

全部完成

2

自动拆批合并

0

发现编造

10 个整理模板准确性实测报告

结论先行：10 个整理模板全部实测跑通（12 次任务、0 次失败），**产出可用、抽取准确、未发现编造**。三条核心纪律全部被模型遵守：只依据记忆原文、缺失如实写「记录中未提供」、结论带 **[M#]** 来源标注。多记忆聚合的自动拆批 + 合并（Map→Reduce）也验证通过——包括**正确识别出一次同名客户冲突**。发现 4 个值得修的小问题，都不是阻断性的。

1. 测试设计

1.1 素材：10 段口语化录音（新增）

为每个整理模板各定制 1 段「双角色对话」录音（macOS **say** TTS 合成，顾问=Ting-Ting / 家长·主管=Mei-Jia），**刻意写成闲聊语气**——带语气词、自我更正、跑题补充，用最接近真实口述的输入去考验抽取能力：

#	录音（对应模板）	时长	埋进去的可抽取要素
01	周例会盘线索 → lead_followup	2:52	6 条线索、状态分组、48h 回访、爽约原因
02	电话邀约遭推迟 → outreach_review	1:59	触达方式、拒绝理由、换到约定的做法、约定下周二
03	家长来电三件事 → parent_review	2:20	咬伤/退费/过敏 3 类问题、承诺 17:00 前回复
04	首次到店面谈 → visit_review	2:51	需求点、决策人、报价、4 类异议、下一步
05	体验课课后反馈 → trial_review	2:41	课程环节、孩子表现、转化信号、顾虑
06	本月异议汇总 → objection_ledger	2:42	6 类异议、已用应对、有效性自评
07	新入园适应跟进 → adaptation_followup	2:47	两户家庭、表现、家长情绪、风险信号
08	与老家长闲聊 → referral_mining	2:17	满意原话、转介绍对象、需确认信息
09	本周渠道盘点 → channel_report	2:09	5 个渠道 6 位到访、转化 1、 成本数据缺失
10	月度成交与流失复盘 → win_loss_review	2:31	成交 1 / 流失 1 / 转园 1、可复用判断

音频已归档：[docs/audio/整理模板测试录音/](#)（10 段 / 25.1 分钟 / 11MB）。

1.2 关键环境处理：租户未配 ASR

`models` 表确认无 **ASR 模型**。若直接上传，音频正文会退化成文件名且状态伪成功（`organize_memory_attachments.go:454` 末尾直接返回文件名）。**规避手法**：上传时 `metadata.note_user_edited=true` + 自带对话 HTML 正文 + `metadata.transcript` 全文——记忆正文即真实对话，整理任务读到的输入有保障，同时音频仍可播放（Range GET 验证 206 / `ftyp`）。

⚠ 这意味着本次测的是「正文质量 → 整理质量」这条链，没有测「音频 → 转写」那段。真转写链路要等租户配上 ASR 模型才能测。

1.3 两轮测试

轮次	内容	任务数
第一轮 1:1	每个模板 + 其对应 1 条录音（10 个 manual 配置）	10
第二轮聚合	<code>objection_ledger</code> / <code>win_loss_review</code> 各挂 11 条记忆（新录音 + 10 条旧谈单录音），验证自动拆批 + 合并	2

2. 第一轮结果：10/10 完成，抽取准确

全部任务 `status=completed`、`selected=1` / `processed=1` / `failed=0`。逐模板核对：

模板	抽取准确性核对	缺失处理	判定
线索跟进清单	6 条线索全部识别、分组正确（紧急/待决策/高风险/失联）；48h 回访（轩轩）正确置顶	线索来源、意向课程 → 「记录中未提供」	✓
邀约触达复盘	触达方式=电话、推迟原因=回老家、有效做法 3 条均来自原话（含直接引用「哦可以啊」）	无缺失项	✓
沟通复盘	3 类问题分类正确；跟进时间精确到「2026-10-06 17:00 前」（录音日期+承诺时间推导）	无	✓
到访谈单复盘	决策人结构（妈妈定/爸爸出钱）、4 类异议含决策权限（易漏）全部抽出；卡点判断正确	无	✓
体验课复盘	课程环节（彩虹伞/轮流）、孩子表现（哭约 30 秒）、转化信号（录像发爸爸）全对	补充素材缺失如实标注	✓
顾虑与异议台账	6 类异议（价格/效果/时间/距离/师资/决策链）逐一归并，有效性判断与顾问自评一致	无	✓
入园适应跟进	两户分开写；风险信号只标在朵朵家（门口情绪失控），果果家标「记录中未提供」	果果风险如实标缺失	✓
转介绍机会挖掘	满意原话 3 条为逐字引用；2 类对象（表妹/小区妈妈）；4 条待确认含年龄性别核对	首行「可能对象」标缺失	✓
渠道效果周报	5 渠道 6 到访 1 转化，单位成本全部标「记录中未提供」，未编造	成本字段全标缺失	✓
成交与流失复盘	3 个案例节点回放正确；「决策人不在场」判断提炼准确	无	✓

纪律核查（最重要）：10 份产出里，凡是录音里没有的信息（线索来源、单位成本、转介绍对象空缺处）全部写「记录中未提供」或明确说明缺失，未发现一处编造。

3. 第二轮结果：自动拆批 + 合并验证通过

11 条记忆（估算 1.5 万+ 字符）超过单批预算，自动进入 `job_mode=batch`：

任务	拆批	处理	覆盖率	成果
顾虑与异议台账（多条聚合）	2 批（批1摘要 2244 字 / 批2 1021 字）	11/11, 0 失败	ratio: 1	3318 字, 来源数 11
成交与流失复盘（多条聚合）	2 批	11/11, 0 失败	ratio: 1	2882 字, 来源数 11

合并质量三个亮点：

- 1. **去重与归并正确**：价格异议把新录音与旧「首轮报价与太贵异议」合并成一条，应对方式列了 4 种（含旧录音里的消费锚点、小课包）。
- 2. **冲突识别正确（本次最有价值的发现）**：「可可妈妈」在新录音里是**转园流失**、在旧录音里是**未成交长期跟进**——合并任务没有静默合并，而是生成了「⚠️ 待确认事项」表，逐条对比两批记录并提问「是否同一客户」。
- 3. **引用跨批保留**：合并稿引用写作 `[M#-批次1]` / `[M#-批次2]`，能看出每条结论来自哪一批。

同时这也**实证了此前的架构判断**：`organize_memories` 没有 `subject_id`，同名客户跨记忆会串。本次是测试数据复用名字造成的，但真实业务里「重名家长」是必然存在的——合并能力越强，这个风险越显性。

4. 发现的问题（4 项，均非阻断）

#	问题	证据	定位与建议
1	成果标题被模型自由发挥：{{title}} 占位符由模型填写，产出出现「渠道效果周报（v2）」「顾虑与异议台账（合并汇总）」	渠道周报模板名实际为「渠道效果周报」	建议提示词里明确「标题使用模板名，不要加版本/状态后缀」，或保存成果时用配置名+日期覆盖 H1（成果标题字段本来就是 配置名 · 日期，成本极低）
2	引用明细详略不稳定：{{citations}} 同为模型填写，多数产出带「标题；类型；时间」，trial_review 只写了 [M1]	10 份产出对比	建议 {{citations}} 由系统后处理生成（依据 organize_output_memories 关联表拼装），不依赖模型自觉
3	合并稿「依据」覆盖不全：11 条来源的任务，产出依据列表只列 2—6 条（其余被批次摘要吸收）。机器侧 organize_output_memories 完整记录 11 条，但人看到的依据列表不代表全部输入	两份聚合成果对比	与 #2 同解：依据列表改为系统按关联表生成即可，顺带解决「处理覆盖率 ≠ 体现覆盖率」的观感问题
4	判断性标注与事实的边界：入园适应产出写朵朵家「已被识别为存在退费或投诉倾向的高风险个案」——模板章节确实要求标注风险信号，但这属于模型推断，不是家长或老师的原话	对照录音原文	属模板设计使然（可接受），但建议模板在风险章节注明「判断需标注依据」，避免一线把推断当事实

5. 环境与产物

项	值
工作区	满乐乐 (tenant 10001 / user <code>fc5a8c95-...</code>) , 即 <code>http://localhost:8081/platform/organize/memory</code>
新增记忆	10 条 <code>kind=audio</code> (25.1 分钟, 正文为对话 HTML, <code>transcript</code> 在 metadata)
新增配置	12 个 manual 整理配置 (10 个逐模板 + 2 个聚合测试) , 无定时, 不会自动消耗 LLM
实测任务	12 次整理任务全部 completed, 0 次失败, 0 次 fallback
成果	12 份, 可在「我的整理」页查看 (截图见下)
音频归档	<code>docs/audio/整理模板测试录音/</code> (10 段 m4a)
测试脚本	<code>/tmp/org_test/</code> (<code>scripts.json</code> / <code>build.py</code> / <code>upload.py</code> / <code>run_tests.py</code> / <code>run_batch.py</code>)

验证手段说明：本次不是只看接口返回 200——逐份人工对照录音原文核对抽取项，缺失项逐一确认「原文里确实没有」；音频用 Range GET 验证可播 (206 / `ftyp`) ；前端页面用 headless_shell + CDP 实截图确认用户视角可见。

6. 结论与下一步

1. 可以对外承诺的口径得到实测支撑：「你录进来的，我帮你整理成能用的清单和台账」——抽取、归并、缺失标注三条纪律在口语化输入下依然守住。
2. 批量整理链路（拆批+合并）达到可用水平，且冲突识别表现超出预期。
3. 建议按 §4 的 1→2→3 顺序修引用与标题（都是小改动，1 和 2/3 可以合并成一次「引用系统化」改造）。
4. 待租户配置 ASR 模型后，补测「音频 → 转写 → 整理」全链路——那才是录音类模板的完整形态。